
기말고사 통합 요약 정리

프롬프트 엔지니어링 후반부 (윤리 · 추론 · 에이전트 · 평가 · 자율성)

1. AI 윤리와 사회적 문제

1.1 알고리즘 편향 (Bias)

AI는 데이터를 통해 학습한다. 문제는 데이터가 사회의 과거를 반영한다는 점이다. 따라서 과거에 존재했던 차별, 고정관념, 불평등 구조가 모델 내부에 그대로 학습될 수 있다.

편향은 크게 두 가지로 나뉜다.

1. 할당적 위해

- 채용, 대출, 보험 등 자원 배분에서 특정 집단이 불이익을 받는 경우
- 예: 아마존 채용 AI가 여성 지원자를 낮게 평가한 사례

2. 표상적 위해

- 특정 집단을 왜곡되게 표현
- 예: CEO를 입력하면 백인 남성 이미지가 생성되는 현상

핵심 이해 포인트:

AI는 “의도적으로 차별”하지 않는다.

그러나 학습 데이터에 내재된 구조적 편향을 그대로 재생산할 수 있다.

1.2 유해성 (Toxicity)와 탈옥(Jailbreak)

대형 언어 모델은 확률 기반 생성 모델이다.

선과 악을 이해하지 못하며, 그저 가장 그럴듯한 단어를 예측할 뿐이다.

이로 인해 발생하는 문제:

- 혐오 발언 재현
- 폭력적·위험한 정보 생성
- 규칙 우회 시도 (DAN 모드, 할머니 이야기 등)

Tay 챗봇 사례는 대표적 실패 사례이다.

16시간 만에 인터넷 사용자들의 공격적 언어를 학습해 차별적 발언을 반복했다.

핵심 이해 포인트:

“AI는 의도가 없다. 그러나 출력은 사회적 영향을 가진다.”

1.3 프라이버시 문제

모델은 학습 데이터를 완전히 “이해”하는 것이 아니라 일부를 암기할 수 있다.

위험:

- 개인 정보 유출 가능성
- 기업 기밀 데이터 노출 위험
- 데이터 추출 공격

삼성전자 사례처럼 내부 기밀이 외부 서버로 전달되는 문제도 현실에서 발생했다.

핵심 이해 포인트:

AI 시대에는 데이터 통제가 곧 안전이다.

1.4 AI 저작권 전쟁

저작권 문제는 입력 단계와 출력 단계로 나뉜다.

입력 단계:

- AI 학습에 사용된 데이터는 합법적인가?
- 뉴스 기사, 예술 작품, 이미지의 무단 학습 문제

출력 단계:

- AI가 생성한 결과물의 저작권은 누구에게 있는가?
- 현재 다수 국가: 인간 창작성이 없는 AI 단독 생성물은 보호 대상 아님

핵심 질문:

1. 학습은 복제인가, 공정 이용인가?
2. 창작의 주체는 인간인가, 기계인가?

2. 고급 추론 프롬프트 기법

2.1 Chain of Thought (CoT)

기존 모델은 곧바로 정답을 생성한다.
CoT는 중간 사고 과정을 출력하게 한다.

예:

“Let’s think step by step.”

효과:

- 복잡한 수학 문제에서 성능 향상
- 논리적 오류 감소

단점:

- 모델이 충분히 클 때만 효과적

2.2 Zero-shot CoT

Few-shot 예시 없이도

“Let’s think step by step”만 추가해도 성능 향상 가능

대형 모델의 잠재 추론 능력 활성화 사례

2.3 Self-Consistency

한 번 추론하는 것이 아니라
여러 번 추론 → 다수결 선택

원리:

- 확률적 디코딩
- 여러 사고 경로 생성
- 가장 많이 나온 답을 선택

의미:

AI의 “자가 검산” 메커니즘

2.4 Tree-of-Thought (ToT)

CoT는 직선적 사고이다.

ToT는 분기 탐색 구조이다.

구조:

1. 여러 사고 후보 생성
2. 각 후보 평가
3. 유망한 가지 확장
4. 불필요한 경로 제거

효과:

- 퍼즐, 복잡 계산 문제에서 성능 상승
- 인간의 브레인스토밍 방식과 유사

3. 검색과 행동의 결합

3.1 RAG (Retrieval-Augmented Generation)

문제:

LLM은 최신 정보를 모른다.

환각이 발생한다.

해결:

답변 생성 전에 외부 문서를 검색

구조:

1. 문서 수집 및 벡터화
2. 질문과 유사한 문서 검색
3. 검색 결과 + 질문 → LLM 입력
4. 근거 기반 답변 생성

핵심 비유:

닫힌 책 시험 → 열린 책 시험

3.2 ReAct (Reason + Act)

기존 LLM은 “생각만” 한다.

ReAct는 “생각 + 행동”을 반복한다.

구조:

Thought → Action → Observation → 반복

예:

- 검색
- 계산기 호출
- 코드 실행

의미:

환각 감소

정확도 향상

실제 작업 수행 가능

3.3 Tool Use & Function Calling

LLM은 기본적으로 텍스트 생성기다.

함수 호출은 LLM에게 “손과 발”을 제공한다.

- JSON 기반 호출
- 외부 API 연결
- 이메일 전송, 예약, 계산 등 수행 가능

이로써 AI는

“말하는 AI” → “일하는 AI”로 진화한다.

4. AI 응답 평가 체계

4.1 유창함의 함정

유창성 ≠ 정확성

AI는 그럴듯하게 틀릴 수 있다.
환각은 구조적 문제이다.

4.2 품질 5대 기준

1. 정확성
2. 관련성
3. 완전성
4. 명확성
5. 윤리성

이 다섯 가지를 기준으로 루브릭을 만들어 평가한다.

4.3 자동 평가 vs 휴먼 평가

자동 평가:

- BLEU
- ROUGE
- BERTScore
- LLM-as-a-Judge

휴먼 평가:

- Likert
- Pairwise
- Cohen's Kappa

한계:

- 위치 편향
- 상황함 편향
- 자기 선호 편향

결론:

자동 + 인간 평가의 조합이 필요

5. 피드백 루프와 데이터 플라이휠

5.1 피드백 루프

출력 → 사용자 반응 → 재학습 → 개선

명시적 피드백:

- 별점, 좋아요

암시적 피드백:

- 클릭, 체류 시간
-

5.2 데이터 플라이휠

사용자 증가

→ 데이터 증가

→ 모델 개선

→ 서비스 향상

→ 사용자 증가

넷플릭스, 구글 사례

5.3 부작용

1. 필터 버블

2. 보상 해킹

3. 모델 붕괴

AI는 성능뿐 아니라 왜곡도 증폭시킬 수 있다.

6. 에이전트 시대

6.1 진화 단계

1. Chatbot
 2. Copilot
 3. Agent
 4. Autonomy
-

6.2 현장의 변화

- 자율 코딩 에이전트
- 업무 생산성 에이전트
- 웹 탐색 에이전트

AI는 실행 가능한 작업 단위로 진화 중이다.

6.3 자율성의 딜레마

- 환각 기반 행동 위험
 - 무한 루프
 - 책임소재 문제
 - Agent as a Service(AaaS)
-

7. 자율성 시대의 인간 역할

AI가 자율성을 가질수록
인간은 다음 역할을 맡는다.

1. Goal Setter
2. Reviewer
3. 감독자(Human-in-the-loop)

핵심 문장:

AI가 자율적으로 행동할수록
책임과 방향 설정은 인간의 몫이다.